

7. Conjunto de datos o datasets.

Todo proceso de aprendizaje automático parte de un **conjunto de datos (dataset)** que describe un fenómeno observable.

Un *dataset* es una **colección de observaciones** (también llamadas **instancias o ejemplos**), en las que cada observación se representa mediante un conjunto de **atributos o variables**.

- **Observaciones** → cada fila representa un caso concreto (ejemplo: un paciente, una transacción, una imagen).
- **Atributos o variables** → cada columna describe una característica de la observación (ejemplo: presión arterial, edad, colesterol).
- **Valores faltantes (missing values)** → algunos atributos pueden no tener valor registrado para ciertas observaciones, ya sea porque no se conoce o porque no se ha podido medir.

Ejemplo

Un *dataset* sobre **enfermedades del corazón** podría contener miles de registros de pacientes. Cada observación incluiría valores de atributos como:

- Presión arterial
- Nivel de colesterol
- Peso y altura
- Sexo
- Pulsaciones en reposo
- Práctica de actividad física

Además, para que el modelo pueda **aprender a predecir** la presencia de enfermedades del corazón, el *dataset* debería incluir una variable adicional denominada **etiqueta o variable objetivo (target)**, que indique si cada paciente ha padecido o no una enfermedad cardíaca.

- **Aprendizaje supervisado:** si se dispone de esa etiqueta, el modelo puede entrenarse para predecir el riesgo de enfermedad en nuevos pacientes.
- **Aprendizaje no supervisado:** si no se dispone de la etiqueta, solo sería posible **agrupar** a los pacientes en clústeres según sus similitudes, pero no predecir la probabilidad de enfermedad.

Formato y organización

Un *dataset* suele organizarse de manera muy similar a una **tabla en una base de datos relacional** o a un fichero de texto en **formato CSV** (*Comma-Separated Values*):

- Cada **fila** → una observación.
- Cada **columna** → un atributo o variable.
- La **primera fila** en un CSV suele contener los nombres de los atributos.

Ejemplo simplificado en CSV:

```
ID,Edad,Sexo,Colesterol,Presión_Arterial,Actividad_Física,Enfermedad_Corazón
1,55,Hombre,240,140,Sí,Sí
2,47,Mujer,200,120,No,No
3,63,Hombre,180,150,Sí,Sí
```

En conclusión: el *dataset* es la **base fundamental del aprendizaje automático**, ya que sin datos de calidad, completos y representativos, ningún modelo de IA puede entrenarse de manera efectiva.

8. Modelo.

Un **modelo de inteligencia artificial (IA)** es una **representación matemática o computacional** que se entrena para llevar a cabo tareas específicas, como **reconocer patrones, hacer predicciones o tomar decisiones**, a partir de datos de entrada.

Los modelos de IA se construyen mediante **algoritmos y técnicas matemáticas**, con el objetivo de **aprender de los datos** y mejorar progresivamente su rendimiento en la tarea para la que fueron diseñados.

Relación entre modelo y algoritmo

En el ámbito del *Machine Learning*, los términos **modelo** y **algoritmo** suelen usarse de manera cercana, aunque no son exactamente lo mismo:

- Un **modelo** es la **función matemática aprendida** que asocia a cada valor de entrada x una salida estimada $\hat{y}=f(x)$.

$$\hat{y}=f(x)$$

- El **algoritmo** es el **procedimiento de cálculo** que permite construir y ajustar el modelo, es decir, encontrar la mejor forma de la función f a partir de los datos.

Dicho de otro modo: el modelo es el **resultado entrenado** que realiza predicciones, mientras que el algoritmo es el **método utilizado para entrenarlo**.



Cuando trabajamos con técnicas de **Machine Learning** o **Deep Learning**, el punto de partida es un **conjunto de datos de entrenamiento**. Estos datos representan experiencias pasadas y sirven para que el algoritmo de aprendizaje —ya sea un modelo clásico de *machine learning* o una red neuronal— pueda **extraer patrones y construir una representación interna** del problema.

Este aprendizaje se lleva a cabo **ajustando una función matemática** que depende de una serie de **parámetros internos**. Dichos parámetros se van modificando de manera progresiva hasta que la función es capaz de realizar **predicciones precisas**.

A esa función matemática con parámetros ajustables la llamamos **función hipótesis**. El entrenamiento consiste, por tanto, en **modificar los valores de los parámetros** de la función hipótesis para que encaje lo mejor posible con los datos de entrenamiento.

Cuando proporcionamos los datos al algoritmo, este inicia un **proceso de optimización**, en el que compara las predicciones con los valores reales y corrige los parámetros para reducir los errores. De este modo, el algoritmo “aprende” de la experiencia pasada.

Al finalizar el entrenamiento, obtenemos una **función hipótesis ajustada**, es decir, un **modelo entrenado**. Este modelo es capaz de **generalizar a datos nuevos**: puede recibir ejemplos que no estaban en el conjunto de entrenamiento y realizar predicciones sobre ellos.



Implementación práctica

El algoritmo se implementa mediante un **programa escrito en un lenguaje de programación** (como Python, R o Java), utilizando librerías y entornos de *machine learning* (ej. TensorFlow, PyTorch, Scikit-learn).

En resumen:

- **El modelo es la función entrenada** que transforma entradas en salidas.
- **El algoritmo es el proceso** que permite entrenar esa función a partir de los datos.

Pseudocódigo de entrenamiento:

```
datos = cargar_dataset()
modelo = inicializar_modelo()
mientras no coincide:
    predicciones = modelo.predecir(datos.entradas)
    error = calcular_error(predicciones, datos.salidas)
    modelo.ajustar_parametros(error)
guardar(modelo)
```

Pasos clave en el entrenamiento de un modelo de IA

1. Datos de entrenamiento

- El modelo recibe datos **etiquetados** (en aprendizaje supervisado) o **no etiquetados** (en aprendizaje no supervisado).
- A partir de ellos, identifica **patrones, relaciones y estructuras**.

2. Algoritmo de aprendizaje

- Es el método matemático que ajusta los parámetros internos del modelo.
- Ejemplo: un algoritmo de clasificación aprende a distinguir entre “gato” y “perro” corrigiendo sus parámetros para reducir errores.

3. Función de pérdida (o función objetivo)

- Calcula la diferencia entre las predicciones del modelo y los resultados reales.
- El objetivo es **minimizar esta pérdida**, acercando las predicciones del modelo a la realidad.

4. Optimización

- El algoritmo ajusta los parámetros internos (por ejemplo, los pesos en una red neuronal) usando técnicas como **gradiente descendente**.
- Con cada iteración, el modelo mejora su rendimiento.

Ejemplo: Un modelo entrenado para **clasificar imágenes** puede recibir como entrada una foto y determinar si contiene un “**gato**” o un “**perro**”. Durante el entrenamiento, el modelo ajusta sus parámetros comparando sus predicciones con las etiquetas reales. Una vez entrenado, será capaz de analizar imágenes nuevas y realizar predicciones de forma autónoma.

En conclusión: **un modelo de IA se construye y entrena mediante un proceso de aprendizaje**, en el que los algoritmos ajustan los parámetros de una función hipótesis hasta que el modelo puede generalizar a nuevas situaciones y realizar predicciones útiles.

A. Similitudes con un algoritmo matemático: No entra este apartado

Un **modelo de inteligencia artificial (IA)** comparte varias características con un **algoritmo matemático tradicional**, ya que ambos se fundamentan en principios matemáticos y lógicos para resolver problemas. Entre las similitudes más destacadas se encuentran:

1. **Uso de ecuaciones y funciones matemáticas.** Tanto en los algoritmos matemáticos como en los modelos de IA se emplean **funciones y ecuaciones** para representar relaciones entre variables.
 - En los algoritmos matemáticos, estas funciones permiten calcular soluciones exactas a un problema.
 - En IA, las funciones se utilizan para calcular la **función de pérdida**, actualizar los **parámetros internos** y realizar **predicciones** sobre los datos.
2. **Optimización.** Ambos enfoques buscan **encontrar la mejor solución posible** dentro de un espacio de alternativas.
 - En IA, el entrenamiento del modelo consiste en **ajustar parámetros** para minimizar una función de pérdida.
 - En matemáticas, los algoritmos de optimización buscan **minimizar o maximizar** una función objetivo, o resolver un sistema de ecuaciones de manera óptima.
3. **Entradas y salidas.** Tanto un modelo de IA como un algoritmo matemático funcionan como un **proceso de transformación**:
 - Reciben **datos de entrada** (valores iniciales, variables, ejemplos).
 - Procesan esa información según un conjunto de reglas o funciones.
 - Devuelven un **resultado de salida**, ya sea una solución exacta o una predicción estimada.

4. **Estructura lógica.** Ambos siguen una **secuencia de pasos bien definidos** para resolver un problema.

- En los algoritmos matemáticos, estos pasos suelen ser fijos y deterministas.
- En los modelos de IA, la lógica incluye procesos como el **preprocesamiento de datos, ajuste iterativo de parámetros y generación de predicciones**, pero sigue siendo una estructura ordenada y coherente.

B. Diferencias clave:

Capacidad de aprendizaje

- La diferencia más importante es que un **modelo de IA puede aprender de los datos**. A medida que recibe más ejemplos, ajusta sus parámetros internos y mejora su rendimiento en la tarea.
- En cambio, un **algoritmo matemático tradicional** sigue siempre un conjunto de reglas fijas y predefinidas: no se adapta ni evoluciona con la experiencia, ni mejora sus resultados con el tiempo.

Complejidad

- Los **modelos de IA modernos**, especialmente las **redes neuronales profundas (deep learning)**, pueden contener miles o incluso millones de parámetros ajustables. Esta enorme cantidad de variables les permite representar patrones muy complejos, pero también los hace difíciles de interpretar.
- Los **algoritmos matemáticos tradicionales**, en general, son **más simples, transparentes y deterministas**, lo que significa que siempre producen el mismo resultado si se les da la misma entrada.

Capacidad para resolver tareas no estructuradas

- Los **algoritmos matemáticos** suelen aplicarse a **problemas bien definidos**, con soluciones exactas o procedimientos establecidos (por ejemplo, resolver una ecuación o calcular un mínimo).
- Los **modelos de IA** pueden abordar **tareas no estructuradas** y ambiguas, como el **reconocimiento de voz, la clasificación de imágenes o la traducción automática**, en las que no existe una solución matemática única ni exacta, sino predicciones aproximadas basadas en patrones aprendidos.

9. Limitaciones de los modelos.

Hasta ahora hemos asumido que es posible encontrar un modelo que se ajuste de manera adecuada a los datos disponibles. Sin embargo, en la práctica, **ningún modelo puede proporcionar una explicación completa y perfecta** de un fenómeno observable.

En general, siempre existen dos componentes en los datos:

- Una parte **predecible**, que puede ser explicada mediante un modelo.
- Una parte **aleatoria o impredecible**, que por su naturaleza no puede ser capturada por ningún modelo, por sofisticado que sea.

Ejemplo extremo: el lanzamiento de una moneda

En este caso, no existen variables, atributos ni características que determinen el resultado. El evento es esencialmente **aleatorio**, y ningún modelo podrá predecir con certeza si saldrá cara o cruz.

Ejemplo práctico: predicción de enfermedades

A diferencia del lanzamiento de una moneda, en el caso de las enfermedades es posible identificar **factores influyentes** (hábitos de vida, características biológicas, antecedentes médicos, etc.). Estos atributos permiten a un modelo estimar probabilidades, pero siempre quedará una parte de la variabilidad de los datos que el modelo **no podrá explicar del todo**.

Causas por las que un modelo no logra explicar completamente los datos

1. Deficiencias en el modelo

- El modelo puede no considerar variables relevantes que influyen en el fenómeno.
- En estos casos, podría ampliarse el *dataset* con nuevos atributos o incluso probar un tipo de modelo diferente más adecuado.

2. Conjunto de datos insuficiente

- Para entrenar correctamente un modelo es necesario contar con un **volumen suficiente de datos**, que refleje la diversidad de situaciones reales.
- Un dataset pequeño o poco representativo limitará la capacidad de generalización del modelo.

3. Errores en los datos

- Los datos pueden contener **mediciones inexactas, registros incompletos o valores incorrectos**.

- Estos errores introducen ruido adicional y reducen el rendimiento del modelo.

4. Componentes puramente aleatorias

- Hay factores imposibles de explicar mediante modelos, porque son esencialmente **aleatorios**.
- Esta parte incontrolable se denomina **ruido** (*noise*, en inglés) y afecta negativamente a las métricas de evaluación del modelo.

En resumen:

- Con un conjunto de datos **suficiente, representativo y de calidad**, junto con la elección de un **modelo adecuado**, es posible obtener resultados muy buenos.
- Sin embargo, siempre existirá una **componente aleatoria irreductible** que ningún modelo podrá explicar. Reconocer esta limitación es fundamental para interpretar correctamente los resultados de cualquier sistema de IA o de *machine learning*.