

Apuntes tema 2

Principios de los sistemas de aprendizaje automático

El **aprendizaje automático (Machine Learning)** comparte límites con la estadística o la matemática aplicada.

Permite **crear sistemas** capaces de mejorar su rendimiento de **manera autónoma** a medida que adquieren experiencia o procesan más datos.

Gracias al aprendizaje automático, los sistemas de IA se vuelven **adaptativos** (aprende de los datos y ajusta su comportamiento).

Dentro del aprendizaje automático se encuentra el **aprendizaje profundo (Deep Learning)** una subdisciplina basada en **redes neuronales artificiales** con múltiples capas.

Bases del aprendizaje automático

- **Capacidad de aprender a partir de la experiencia:** Los sistemas aprenden de los **datos** (ejemplos del mundo real).
- **El algoritmo como mecanismo de aprendizaje:** Los datos se **introducen** en un algoritmo matemático, que **analiza** la información, **detecta** patrones y **construye** un modelo.
- **Predictión y mejor continua:** Una vez entrenado el modelo puede **aplicarse a nuevos datos**, si este no da resultados satisfactorios puede **reentrenarse** para mejorar su rendimiento.

Un ejemplo puede ser el filtro de spam que utiliza técnicas de aprendizaje automático.

Enfoque tradicional

Un analista realizaba un análisis manual del problema, para ello **recogía correos** identificados como spam y **buscaba** patrones. A partir de estas observaciones el analista elaboraba un conjunto de reglas (motor de reglas) que definía las condiciones para definir si un correo es spam o no.

El **motor de reglas** se compone de un **conjunto de condiciones** programadas manualmente que permiten distinguir entre un correo electrónico legítimo y uno de spam.

Una vez definido el conjunto de reglas **se prueban** utilizando correos nuevos para comprobar la capacidad de clasificación. Si lo hace de forma **correcta** el sistema puede ser **implementado en producción**, si no se inicia una **fase de análisis de errores**, donde se revisan que reglas **no están funcionando** correctamente, cuales son **irrelevantes** y que **nuevas** condiciones podrían añadirse.

El enfoque tradicional **depende del analista** ya que es él el que realiza todo el trabajo. Además este sistema se basa en **reglas estáticas** por lo que deben ser revisadas y actualizadas de forma periódica ya que puede quedar obsoleto si los patrones cambian.

Aprendizaje automático

Aquí el **sistema aprende de los datos** y es capaz de adaptarse de forma autónoma a los nuevos patrones.

El analista se encarga de **reunir los datos** representativos del problema y de **seleccionar el algoritmo** matemático que considere más adecuado para resolverlo.

Una vez elegido el algoritmo empieza la **fase de entrenamiento** donde **proporciona los datos** al sistema de aprendizaje automático, en este proceso el algoritmo ajusta sus parámetros hasta que construye un modelo capaz de reconoce patrones.

Una vez entrenado el modelo se somete a una **fase de evaluación** en la que se verifica si el modelo **realiza su trabajo correctamente**, si la solución es satisfactoria se implementan en producción.

En caso de que las predicciones del modelo no sean correctas o imprecisas se vuelve a la **fase de análisis de errores** y se evalúa la calidad de los datos utilizados o si el algoritmo seleccionado es el correcto.

¿Cuándo utilizar Machine Learning?

El Machine Learning se utiliza en los siguientes casos:

- Cuando las soluciones se basan en un **conjunto extenso de reglas** cuya gestión manual resulta compleja o ineficiente.
- En problemas complejos donde un analista no puede **definir fácilmente una solución** a partir de la información disponible, debido a la cantidad, variabilidad o ambigüedad de los datos.

- En entornos que **cambian** con frecuencia o presentan comportamientos **impredecibles**, donde las reglas fijas dejan de ser efectivas con el tiempo.
- Como **apoyo** a los métodos tradicionales de análisis

Clasificación de los sistemas de Machine Learning

El criterio más común para clasificar los sistemas y técnicas de aprendizaje automático se basa en **como** el modelo se entrena y se **ajusta** a lo largo del tiempo

Los métodos de Machine Learning pueden agruparse en varias categorías:

- Según en la forma que se entrenan:
 - **Aprendizaje supervisado:** El modelo aprende a partir de **datos etiquetados**.
 - **Aprendizaje no supervisado:** El modelo trabaja con **datos sin etiquetar**.
 - **Aprendizaje semi-supervisado:** **Combina** datos etiquetados y no etiquetados para mejorar la precisión del modelo.
 - **Aprendizaje por refuerzo:** El sistema aprende mediante la **interacción** con un **entorno**.
- Según la forma en que aprenden con el tiempo:
 - **Aprendizaje online:** El modelo se **actualiza de manera continua** conforme recibe nuevos datos.
 - **Aprendizaje batch (por lotes):** el modelo se entrena de **una sola vez** con un conjunto completo de datos y no se actualiza hasta que se entrena nuevamente.
- Según la forma en que realizan las predicciones:
 - **Aprendizaje basado en instancias:** Las predicciones se realizan comparando **nuevos datos** con **ejemplos almacenados** en el conjunto de entrenamiento.
 - **Aprendizaje basado en modelos:** El sistema construye una **representación general del problema** a partir de los datos y utiliza esa abstracción para realizar predicciones

Técnicas y herramientas de aprendizaje automático

Existen diferentes técnicas de aprendizaje automático, las más utilizadas son:

- **Regresión lineal y regresión logística:** Empleadas para **predecir valores numéricos** continuos o **clasificar datos** en categorías simples.
- **Árboles de decisión y bosques aleatorios (Random Forest):** Útiles en tareas de **clasificación** y **toma de decisiones** (múltiples variables)
- **K-Means:** técnica de aprendizaje no supervisado que permite **agrupar datos** en clústeres o grupos según su similitud.
- **Redes neuronales artificiales:** Modelos inspirados en el funcionamiento del cerebro humano, ampliamente utilizados en **reconocimiento de imágenes**, **procesamiento de voz** y **texto**.

Para implementar estas técnicas existen herramientas y bibliotecas como:

- **Scikit-learn:** Biblioteca de Python ampliamente utilizada para el **aprendizaje automático clásico**.
- **Weka y Orange:** Entornos gráficos interactivos que permiten experimentar con diferentes algoritmos sin necesidad de programar.
- **TensorFlow y Keras:** Bibliotecas de alto rendimiento diseñadas para el desarrollo de **modelos avanzados** y de **aprendizaje profundo**.

Técnicas

La **elección** de la técnica y la herramienta más adecuada **depende del tipo de problema** a resolver, la cantidad y calidad de los datos disponibles y el nivel de complejidad que se desee alcanzar, el objetivo es seleccionar la que **mejor** se adapte a la naturaleza de los datos y que proporcione resultados precisos, interpretables y eficientes.

Aprendizaje supervisado

En este sistema el modelo aprende a partir de **ejemplos etiquetados**.

Se parte de un conjunto de **datos de entrenamiento** que contiene pares de entrada y salida conocidos. Estos se **añaden** al algoritmo de aprendizaje el cual ajusta sus parámetros internos para encontrar una función que relacione correctamente las entradas con las salidas. El resultado es el modelo (**función hipótesis**) que posteriormente se utiliza para realizar predicciones.

La principal característica es que se necesitan ejemplos etiquetados (conjunto de datos etiquetados) para poder aprender la relación entre las entradas y las salidas (función hipótesis).

Una vez entrenado el modelo puede aplicarse a **nuevos datos** no etiquetados.

Dentro del aprendizaje supervisado encontramos dos subcategorías principales:

- **Regresión:** Se utiliza cuando el objetivo es **predecir valores continuos** (estimar el precio de una vivienda, predecir el coste económico de un incidente de seguridad, seguridad informática).
- **Clasificación:** Se utiliza cuando el objetivo es **predecir valores discretos**, es decir, resultados que pertenecen a un conjunto limitado y definido de categorías. El modelo asigna cada ejemplo a una clase concreta.

Aprendizaje no supervisado

El aprendizaje no supervisado consiste en crear una función que describa la estructura interna de un conjunto de datos sin etiquetar.

Características del aprendizaje no supervisado

- **Crea una función** que les permite descubrir relaciones o patrones ocultos dentro de los datos.
- El **objetivo** es **escribir y organizar** los datos que se le proporcionan.
- Los datos de entrada **no están etiquetados**.

Estos algoritmos trabajan a partir de un **conjunto de datos sin etiquetar**, que se proporciona a un **algoritmo de aprendizaje automático**. El algoritmo, a partir de esos datos, **crea una función hipótesis**, que describe las relaciones o patrones existentes entre los elementos del conjunto.

Asociación entre técnicas, herramientas y tipos de sistemas

Cada tipo de aprendizaje automático se vincula con técnicas y herramientas específicas, adaptadas a la naturaleza del problema y al tipo de datos con los que se trabaja:

- **Aprendizaje supervisado:** Utiliza técnicas como la **regresión lineal**, los **árboles de decisión**, las **máquinas de vectores de soporte (SVM)** o las

redes neuronales. Estas técnicas se implementan con bibliotecas como Scikit-learn o TensorFlow, que permiten entrenar modelos a partir de datos etiquetados.

- **Aprendizaje no supervisado:** Emplea métodos como K-Means, PCA (Análisis de Componentes Principales) o algoritmos de agrupamiento jerárquico, cuyo objetivo es descubrir patrones y estructuras ocultas en los datos. Se utilizan herramientas como Weka, Orange y Scikit-learn.
- **Aprendizaje semi-supervisado:** Combina datos etiquetados y no etiquetados para mejorar la precisión del modelo. Se apoya en modelos híbridos y se implementa con Scikit-learn o TensorFlow.
- **Aprendizaje por refuerzo:** Se basa en técnicas como Q-Learning o Deep Q-Networks (DQN), en las que el agente aprende mediante prueba y error, recibiendo recompensas o penalizaciones según sus acciones. Este tipo de aprendizaje se desarrolla principalmente con TensorFlow y Keras.

La elección de la técnica y herramienta depende directamente del tipo de aprendizaje automático y de los objetivos del problema a resolver. Mientras que los enfoques supervisados se orientan a la predicción y clasificación, los no supervisados buscan descubrir patrones y estructuras ocultas en los datos. Los modelos semi-supervisados combinan ambos enfoques para aprovechar la información disponible de manera más eficiente, y los algoritmos de refuerzo se aplican cuando el sistema debe aprender mediante la interacción con un entorno cambiante.

