Apuntes tema 3

Aprendizaje supervisado

1. Fundamentos del Aprendizaje Supervisado

Se define por el entrenamiento de algoritmos mediante un conjunto de datos que ya contiene la respuesta correcta, denominada **etiqueta (label)** o **target**.

Mecánica Operativa

El sistema opera mediante la interacción de dos elementos clave:

- **Características de entrada (Features):** Variables de entrada que describen cada ejemplo.
- **Salida o Etiqueta (Target):** El valor o categoría que el modelo debe aprender a predecir.

El objetivo final es que el modelo detecte la relación entre las entradas y salidas para poder hacerlo con datos nuevos.

2. Tipos de Problemas y Algoritmos

La naturaleza del problema supervisado se determina según el tipo de salida que se desea obtener.

A. Clasificación

Se utiliza cuando el objetivo es predecir una clase o categoría discreta (un conjunto limitado de opciones).

- **Ejemplos:** Detección de spam, diagnóstico médico (positivo/negativo), reconocimiento de imágenes.
- **Algoritmos representativos:** Regresión logística, Árboles de decisión, Random Forest, SVM (Máquinas de Vectores de Soporte) y Redes neuronales.

B. Regresión

Se aplica cuando el objetivo es predecir un valor numérico continuo dentro de un rango infinito.

- **Ejemplos:** Predicción de precios de mercado, cálculo de tiempos de entrega, estimaciones meteorológicas.
- **Algoritmos representativos:** Regresión lineal, SVR (Regresión con SVM), Random Forest Regressor y Redes neuronales.

3. El Pipeline de Machine Learning

El flujo de trabajo estándar para desarrollar un modelo supervisado sigue una secuencia lógica de ocho pasos:

1. **Recolección:** Obtención de información relevante.
2. **Etiquetado:** Asignación de la respuesta correcta a cada muestra (crucial si el dataset original no las tiene).
3. **Limpieza y Preparación:** Tratamiento de errores y normalización.
4. **División del Dataset:** Partición en conjuntos de entrenamiento, validación y prueba.
5. **Entrenamiento:** Aplicación del algoritmo sobre los datos.
6. **Evaluación y Optimización:** Medición de precisión y ajuste de parámetros.
7. **Prueba (Test):** Validación con datos nuevos para verificar el rendimiento real.
8. **Producción:** Aplicación del modelo en un entorno real.

4. Preparación y Limpieza de Datos

La calidad de un modelo es directamente proporcional a la calidad de sus datos. Esta fase suele consumir más tiempo que el entrenamiento mismo.

Tratamiento de Registros e Integridad

- **Eliminación de duplicados:** Para evitar que el modelo memorice patrones artificiales en lugar de aprender patrones reales.
- **Gestión de valores nulos (missing values):** Contamos con la eliminacion si son pocos datos los que se borran o imputación con una media, mediana o moda.
- **Detección de Outliers (Valores atípicos):** Valores extremos que distorsionan las medias. Se identifican mediante análisis visual (boxplots) o

métodos estadísticos (Z-score, IQR). Se pueden eliminar o limitar mediante *clipping*.

Transformación de Variables

Los algoritmos requieren que los datos estén en un formato numérico y, frecuentemente, en escalas similares.

Técnica	Descripción	Uso Recomendado
Min-Max Scaling	Transforma valores al rango [0, 1].	Modelos basados en distancias (KNN), Redes Neuronales.
Standard Scaling	Ajusta datos a Media=0 y Desviación=1.	Modelos lineales, SVM, PCA; menos sensible a outliers.
Label Encoding	Asigna un número a cada categoría.	Datos donde existe un orden intrínseco.
One-Hot Encoding	Crea columnas binarias por categoría.	La mayoría de los modelos; evita órdenes artificiales.

5. Estrategias de División y Estratificación

Para garantizar que la evaluación del modelo sea justa y representativa, el dataset se divide generalmente en tres bloques:

- **Entrenamiento (Train):** 60-70% de los datos.
- **Validación (Validation):** 15-20% para ajuste de hiperparámetros.
- **Prueba (Test):** 15-20% para la evaluación final.

La Importancia de la Estratificación

La estratificación asegura que la proporción de cada clase se mantenga constante en todos los subconjuntos, lo que permite:

- Una evaluación más justa y precisa.
- Reducción de la variabilidad de las métricas.
- Garantizar que el modelo aprenda a identificar la clase minoritaria de manera efectiva.

Aprendizaje supervisado: Regresión lineal

1. Características Principales de la Regresión Lineal

La regresión lineal se define por una serie de atributos técnicos que determinan su funcionamiento y aplicación:

- **Aprendizaje Supervisado:** El algoritmo aprende a partir de un conjunto de datos previamente etiquetados.
- **Basado en Modelo:** Se centra en la construcción de una función hipótesis que represente la relación entre los datos.
- **Modelo Lineal:** Utiliza una función lineal para realizar predicciones.
- **Predicción Mediante Suma Ponderada:** El resultado se obtiene computando una suma ponderada de las características de entrada, a la que se añade una constante de sesgo o *bias*.
- **Salida Continua:** Su propósito fundamental es predecir valores numéricos dentro de un rango continuo (por ejemplo, el coste económico de un incidente).

2. Notación y Estructura de Datos

Para el desarrollo del modelo, se utiliza una notación estandarizada que permite organizar la información del conjunto de entrenamiento (*dataset*):

Símbolo	Definición
m	Número total de ejemplos en el conjunto de datos.
x	Variable de entrada o característica (*feature*).
y	Variable de salida o valor objetivo (*target*).
n	Número de variables de entrada disponibles.
(x, y)	Representación de un único ejemplo de entrenamiento.

3. La Función Hipótesis

La función hipótesis es la expresión matemática que aproxima la relación entre las variables de entrada y la salida. El proceso general sigue el flujo: **Conjunto de datos → Función hipótesis → Modelo → Predicciones.**

3.1. Tipos de Regresión Lineal

Dependiendo del número de variables de entrada, la función varía:

1. **Regresión Lineal Univariable (Unidimensional):** Se emplea cuando solo existe una característica de entrada. Su fórmula es: $h\theta(x)=\theta 0+\theta 1x$
2. **Regresión Lineal Multivariable (Multivaluada):** Se utiliza cuando existen múltiples características de entrada (x_1, x_2, ..., x_n): $\theta(x)=\theta 0+\theta 1x1+\theta 2x2+\theta 3x3+... +\theta NxN$

3.2. Parámetros del Modelo

El comportamiento y la precisión de la recta de regresión dependen de los parámetros θ:

- **θ0** es el punto con el que corta en el eje y.
- **θ1** indica la pendiente (inclinación de la recta).

4. Evaluación mediante la Función de Coste

Una vez inicializados los parámetros, es necesario medir qué tan precisas son las predicciones del modelo. Para ello se utiliza la **función de coste** o función de error.

4.1. Error Cuadrático Medio (MSE)

Es la métrica más utilizada en regresión lineal. Cuantifica la diferencia entre la predicción de la función hipótesis y el valor real del dato etiquetado. El cálculo sigue estos pasos:

1. Calcular la diferencia entre la predicción y el valor real para cada ejemplo.
2. Elevar dicha diferencia al cuadrado (lo que asegura valores positivos y penaliza errores grandes).
3. Sumar todos los errores individuales.
4. Calcular el promedio dividiendo entre el número de ejemplos (m) y, por convención matemática, entre 2.

Un valor de coste alto indica que el modelo no se ajusta a la tendencia de los datos, mientras que un valor bajo indica un ajuste óptimo.

5. Optimización: Descenso por Gradiente (Gradient Descent)

El objetivo del entrenamiento es encontrar los valores de θ0 y θ1 que minimicen la función de coste. La técnica predominante para lograr esto es el **Descenso**

por Gradiente.

5.1. El Concepto de Mínimo Global

En la regresión lineal, la función de coste suele tener una forma convexa. Esto garantiza la existencia de un único **mínimo global**, que es el punto exacto donde el error es el menor posible.

5.2. Funcionamiento del Algoritmo

El Descenso por Gradiente ajusta los parámetros de forma iterativa siguiendo estos principios:

- **Cálculo del Gradiente:** El gradiente es equivalente a la derivada o pendiente de la función en un punto dado.
- **Dirección del Ajuste:** El gradiente indica la dirección en la que el error aumenta; por lo tanto, el algoritmo mueve los parámetros en la dirección opuesta para reducir el error.
- **Proceso Iterativo:** El algoritmo modifica gradualmente θ hasta que la pendiente es cero (línea horizontal), lo cual indica que se ha alcanzado el mínimo global y los parámetros son óptimos.

Este proceso de minimización del error mediante el ajuste de parámetros es lo que constituye técnicamente el **entrenamiento** de un algoritmo de Machine Learning.

Aprendizaje Supervisado: Regresión logística

1. Definición y Propósito del Modelo

La regresión logística es una técnica de clasificación **(aprendizaje supervisado)** que computa una suma ponderada de las características de entrada más un sesgo (*bias*), aplicando posteriormente una función de activación para determinar la pertenencia a una clase.

- **Clasificación Binaria:** El modelo intenta predecir valores discretos:
  - **0:** Clase negativa (ej. "no spam").
  - **1:** Clase positiva (ej. "spam").

- **Naturaleza:** Se considera un modelo lineal generalizado.

2. Diferencias entre Regresión Lineal y Logística

Aunque ambos modelos comparten la base de una combinación lineal de variables, sus objetivos y comportamientos son diferentes:

Característica	Regresión Lineal	Regresión Logística
Tipo de predicción	Valores continuos en rango amplio.	Valores discretos (normalmente 0 o 1).
Transformación	Ninguna (suma ponderada directa).	Función logística (sigmoide) aplicada al resultado.
Sensibilidad a datos anómalos	Alta. Valores extremos desplazan la recta y alteran el límite de decisión.	Baja. El resultado está siempre acotado entre 0 y 1.

El fallo de la regresión lineal en clasificación

Al intentar aplicar regresión lineal a problemas de clasificación, la aparición de ejemplos adicionales o valores atípicos puede aplanar la recta de regresión. Esto provoca que el límite de decisión se desplace incorrectamente, generando predicciones erróneas.

3. Construcción de la Función Hipótesis

La función hipótesis ($h_\theta(x)$) en regresión logística garantiza que las predicciones estén siempre en el intervalo [0, 1].

La Función Sigmoide

Para lograr este acotamiento, se utiliza la función sigmoide o logística ($g(z)$):

$g(z)= 1 / 1 + e^{-z}$

Propiedades de la sigmoide:

- Tiene una característica forma en "S".
- Toma el valor **0.5** cuando la entrada (z) es 0.
- Tiende a **1** para valores positivos grandes.
- Tiende a **0** para valores negativos grandes.

Definición Matemática

Para un problema con una sola característica de entrada, la hipótesis se expresa como:

$h\theta(x) = 1 / 1 + e^{-(\theta 0 + \theta 1 x1)}$

4. Interpretación y Probabilidad

La salida de la función hipótesis es la **probabilidad** de que un ejemplo pertenezca a la clase positiva. (y=1).

- Si el modelo devuelve 0.7, indica un 70% de probabilidad de que el correo sea spam.
- Esta salida continua evita las distorsiones por datos anómalos que afectan a la regresión lineal simple.

5. La Función de Coste

La función de coste tradicional de la regresión lineal (mínimos cuadrados) no es apta para la regresión logística. Al combinarla con la función sigmoide, se genera una función de error **no convexa**.

- **Problema de la no convexidad:** Presenta múltiples mínimos locales, lo que impide que los algoritmos de optimización aseguren encontrar el menor valor de error posible.
- **Solución:** Se define una función de coste convexa que garantiza un único mínimo global.

Función de Coste Unificada

La función utilizada penaliza las predicciones incorrectas de forma logística:

$J(h\theta(x),y) = -y \log(h\theta(x)) - 1 (1 - y) \log(1 - h\theta(x))$

Comportamiento de la penalización:

- Si la etiqueta real es y=1 y el modelo predice 0.1 (cercano a 0), el coste es muy alto.
- Si la etiqueta real es y=0 y el modelo predice 0.9 (cercano a 1), el coste es muy alto.
- A medida que la predicción se acerca al valor real, el coste tiende a cero.

6. Límite de Decisión (*Threshold*)

El *threshold* es el umbral que transforma la probabilidad continua en una decisión discreta.

- **Regla estándar:**
  - Si $h_\theta(x) \geq 0.5 \longrightarrow$ Clase 1.
  - Si $h_\theta(x) < 0.5 \longrightarrow$ Clase 0.

Ajuste del Umbral según el Contexto

El valor de 0.5 es habitual pero no obligatorio. Puede modificarse dependiendo del tipo de error que se desee minimizar:

1. **Threshold bajo (ej. 0.3):** Clasifica más ejemplos como clase 1. Útil para reducir **falsos negativos** (ej. diagnóstico médico donde no se quiere omitir un caso positivo).
2. **Threshold alto (ej. 0.7):** Clasifica menos ejemplos como clase 1. Útil para reducir **falsos positivos** (ej. evitar que correos legítimos importantes terminen en la carpeta de spam).

El límite de decisión actúa como una frontera que divide las clases en el espacio de las características de entrada.

Aprendizaje supervisado: KNN

1. Fundamentos del K-NN como Aprendizaje Supervisado

K-NN se clasifica como un algoritmo de aprendizaje supervisado porque requiere de un conjunto de entrenamiento previamente etiquetados. Cada instancia en este conjunto está compuesta por:

- **Características de entrada (Features):** Variables de entrada que describen cada ejemplo.
- **Salida o Etiqueta (Target):** El valor o categoría que el modelo debe aprender a predecir.

Este algoritmo es valorado por ser uno de los métodos más accesibles.

2. La Características del "Lazy Learning"

K-NN no construye un modelo explícito durante el entrenamiento. Esta naturaleza se resume en la siguiente comparativa:

- **Algoritmos convencionales:** "Aprenden antes y predicen rápido".
- **k-NN (Lazy Learning):** "Aprende poco y predice lento".

El entrenamiento consiste exclusivamente en almacenar los datos de entrada. En consecuencia, todo el procesamiento ocurre en el momento exacto en que se solicita una predicción.

3. Mecánica de Funcionamiento

El proceso operativo es secuencial y se activa ante cada nuevo ejemplo sin etiqueta:

1. **Recepción:** Se introduce un dato nuevo.
2. **Cálculo de Distancia:** Se mide la distancia entre el nuevo ejemplo y todos los puntos almacenados.
3. **Selección:** Se identifican los *k* ejemplos más cercanos (los "vecinos").
4. **Decisión:**
    - En **clasificación**, se asigna la clase más frecuente entre los vecinos.
    - En **regresión**, se calcula la media de los valores de los vecinos.

4. El Rol Crítico del Parámetro *k*

La elección del valor de *k* determina la estabilidad y precisión del modelo:

Valor de *k*	Impacto en el Modelo	Riesgos Asociados
Pequeño (ej. k=1)	Toma decisiones basadas en un único vecino. Muy sensible a valores atípicos.	**Sobreajuste (Overfitting)** y alta sensibilidad al ruido.
Grande	El modelo es más estable y reduce la influencia del ruido.	**Subajuste (Underfitting)** y pérdida de detalles locales importantes.

En la práctica, el valor óptimo se halla mediante procesos de validación y pruebas de rendimiento.

5. Métrica de Distancia y el Escalado de Características

Medidas de Similitud

Para cuantificar la cercanía entre puntos, k-NN emplea métricas matemáticas. La más común es la **Distancia Euclídea**, que representa la línea recta entre dos puntos. Otras alternativas incluyen:

- **Manhattan:** Suma de diferencias absolutas.
- **Minkowski:** Una generalización de diversas métricas.
- **Chebyshev:** Basada en la distancia máxima en cualquier dimensión.

Necesidad Obligatoria de Escalado

k-NN es extremadamente sensible a la magnitud de los datos. Si una variable tiene un rango mayor frente a otra menor, la variable mayor dominará el cálculo de distancia, invalidando la similitud real. Por ello, es importante aplicar:

- **StandardScaler:** Ajuste a media 0 y desviación 1.
- **MinMaxScaler:** Transformación de valores al rango entre 0 y 1.

6. Aplicabilidad: Clasificación vs. Regresión

La versatilidad del k-NN le permite abordar dos tipos de problemas fundamentales:

- **Clasificación:** La predicción se basa en un sistema de votación. Por ejemplo, si con *k=5*, tres vecinos pertenecen a la "Clase A" y dos a la "Clase B", el resultado final será "Clase A".
- **Regresión:** La predicción es un valor numérico derivado de la media. Si los vecinos más cercanos tienen valores de 200, 220 y 210, la predicción resultante será 210.

7. Evaluación de Ventajas y Limitaciones

El uso de k-NN debe ser estratégico, considerando sus fortalezas y debilidades inherentes:

Ventajas

- Implementación y comprensión sumamente sencillas.

- No requiere una fase de entrenamiento compleja.
- Versatilidad para tareas de clasificación y regresión.
- Excelente desempeño en conjuntos de datos pequeños.

Limitaciones

- **Eficiencia:** Muy lento durante la fase de predicción.
- **Memoria:** Exige almacenar la totalidad del dataset.
- **Sensibilidad:** Vulnerable al ruido y dependiente crítico del escalado.
- **Escalabilidad:** Poco apto para grandes volúmenes de datos (*datasets* masivos).

En conclusión, k-NN es una herramienta poderosa y fundamental para entender el aprendizaje supervisado, ideal para contextos con datos limitados y características bien definidas, aunque suele ceder ante modelos como SVM o árboles de decisión en entornos de alta complejidad.

Aprendizaje supervisado: Máquinas de Vectores de Soporte (SVM)

1. Fundamentos del Aprendizaje en SVM

El aprendizaje automático consiste en la detección de patrones para realizar predicciones precisas. En este contexto, SVM debe equilibrar dos problemas críticos que afectan a la mayoría de los modelos:

Desafíos del Ajuste de Modelos

Situación	Comportamiento del Modelo	Resultado
Subajuste (Underfitting)	El modelo es demasiado simple; no detecta patrones importantes.	Error alto tanto en entrenamiento como en pruebas.
Buen ajuste	Aprende patrones generales y tendencias reales.	Predicciones correctas con datos nuevos.
Sobreajuste (Overfitting)	El modelo memoriza el ruido y los datos específicos.	Error bajo en entrenamiento, pero alto en validación/test.

Las SVM destacan por mitigar estos problemas mediante la construcción de modelos robustos, siendo especialmente eficaces cuando las fronteras de decisión son difíciles de definir.

2. Funcionamiento y Construcción del Límite de Decisión

A diferencia de otros modelos lineales que buscan cualquier línea que separe las clases, la SVM busca el **mejor límite de decisión posible**.

El Concepto de Margen

El margen es la distancia entre el límite de decisión y los ejemplos de entrenamiento más cercanos de cada clase. El objetivo primordial de SVM es maximizar este margen.

- **Vectores Soporte (Support Vectors):** Son los puntos o ejemplos que se encuentran exactamente sobre las líneas del margen.
- **Ventaja de Generalización:** Al situar la frontera lo más lejos posible de los vectores soporte, se reduce la probabilidad de clasificar erróneamente nuevos datos que caigan cerca de la frontera de decisión.

3. Tipos de Modelos SVM según la Naturaleza de los Datos

El algoritmo puede adaptarse dependiendo de si los datos son linealmente separables o no.

3.1. Clasificación de Margen Duro (Hard Margin Classification)

Este enfoque es estricto y solo es aplicable en situaciones ideales donde los datos están perfectamente separados y no presentan ruido.

- **Restricción:** No permite ningún error de clasificación en el conjunto de entrenamiento.
- **Sensibilidad:** Es extremadamente vulnerable a valores anómalos. Un solo dato mal ubicado puede obligar al modelo a recalcular un límite de decisión o impedir la creación de un modelo.

3.2. Clasificación de Margen Blando (Soft Margin Classification)

Es la variante más utilizada en aplicaciones reales debido a su flexibilidad.

- **Objetivo:** Permitir ciertos errores controlados para obtener un modelo que represente mejor la tendencia global.
- **Robustez:** Minimiza la influencia de los *outliers* y evita que ejemplos extremos distorsionen la frontera de decisión.

4. El Hiperparámetro C y la Regulación del Modelo

La flexibilidad en una SVM se controla mediante el **hiperparámetro C**, que define el grado de penalización de los errores de clasificación durante el entrenamiento.

- **C Alto (Comportamiento de Margen Duro):**
  - Penaliza fuertemente los errores.
  - El modelo intenta clasificar correctamente cada ejemplo.
  - Riesgo elevado de sobreajuste por ajustarse excesivamente a los datos.
- **C Bajo (Comportamiento de Margen Blando):**
  - Penaliza menos los errores, permitiendo clasificaciones erróneas controladas.
  - El modelo es más flexible y robusto frente a datos ruidosos.
  - Incorpora más vectores soporte para definir la frontera basándose en la concentración de datos y no en excepciones.

El valor óptimo de C depende de la naturaleza del dataset y del nivel de ruido, por lo que su selección requiere técnicas sistemáticas de validación.

5. Kernels y Separación No Lineal

En muchos escenarios reales, las clases no pueden separarse mediante una línea recta (datos no linealmente separables). SVM resuelve esto transformando el espacio de los datos.

El Truco del Kernel (Kernel Trick)

SVM utiliza funciones matemáticas denominadas **kernels**.

- **Función:** Calcula la similitud entre ejemplos como si estuvieran en un espacio de mayor dimensión, sin necesidad de realizar la transformación

explícita de los datos.

- **Eficiencia:** Permite trabajar con modelos no lineales manteniendo una complejidad computacional razonable.

Tipos de Kernels Comunes

1. **Lineal:** Para separaciones básicas.
2. **Polinómico:** Genera límites de decisión curvos sin la explosión de características de la regresión polinómica tradicional.
3. **RBF (Gaussiano):** Utilizado para mapeos complejos.
4. **Sigmoide:** Otra variante para estructuras específicas.

Análisis de Modelos de Aprendizaje Supervisado: Árboles de Decisión y Random Forest

1. Fundamentos de los Árboles de Decisión

Los árboles de decisión son clasificadores no lineales. Su funcionamiento se basa en la construcción de un modelo que define límites de decisión a través de una estructura jerárquica de reglas tipo "if–then–else".

Características Principales

- **Versatilidad:** Capacidad para predecir valores continuos y valores discretos.
- **No Linealidad:** Construyen límites mediante particiones sucesivas.
- **Interpretabilidad:** El proceso de decisión es sencillo y fácil de seguir.

Mecanismo de Funcionamiento

El algoritmo busca valores de corte en las características de entrada para separar las clases de la mejor manera posible.

1. **Nodo raíz:** Aplicación de una primera regla.
2. **Partición:** Los ejemplos que cumplen la regla se asignan a un nodo hoja (nodo puro) o a una rama que requiere más divisiones.

3. **Jerarquía:** Se aplican reglas sucesivas hasta alcanzar una predicción final.

2. Limitaciones de los Árboles de Decisión Individuales

A pesar de sus ventajas, los árboles de decisión presentan cuatro limitaciones críticas:

Limitación	Descripción
Sobreajuste (Overfitting)	Tendencia a crear estructuras excesivamente complejas que memorizan el ruido y los detalles específicos de los datos de entrenamiento, perdiendo capacidad de generalización.
Óptimos Locales	La construcción se basa en el mejor corte inmediato por nodo (optimización local), lo que no garantiza una estructura óptima a nivel global.
Inestabilidad	Alta sensibilidad a pequeñas perturbaciones; una mínima variación en el conjunto de entrenamiento puede resultar en un árbol con una estructura completamente diferente.
Complejidad en Datos con Ruido	El problema del sobreajuste se agrava en datasets con muchas características o valores atípicos.

3. Ensemble Learning y el Método Bagging

El **Ensemble Learning** se basa en el principio de que combinar las predicciones de varios modelos genera resultados superiores a los de un modelo individual. Esta técnica se aplica habitualmente en las fases finales de un proyecto de Machine Learning para mejorar la robustez.

El Proceso de Bagging (Bootstrap Aggregating)

El Bagging es la base del algoritmo Random Forest y consta de los siguientes pasos:

1. **Datasets Bootstrap:** Se generan B subconjuntos del dataset original mediante muestreo aleatorio con reemplazo.
2. **Entrenamiento:** Se entrena un modelo independiente sobre cada subconjunto.
3. **Ejemplos Out-of-Bag (OOB):** Los datos que no se incluyen en un subconjunto específico se denominan OOB y sirven para evaluar el

rendimiento del modelo sin necesidad de un conjunto de validación externo (OOB score).

4. **Agregación:**
    - **Clasificación:** Votación mayoritaria entre todos los modelos.
    - **Regresión:** Cálculo de la media o mediana de las predicciones.

4. Random Forest: Sinergia de Aleatoriedad y Agregación

Un **Random Forest** es un conjunto de árboles de decisión que colaboran para realizar una predicción conjunta. Su robustez proviene de dos fuentes de aleatoriedad:

Fuentes de Aleatoriedad

- **Aleatoriedad en los Datos (Bagging):** Cada árbol se entrena con una versión distinta de los datos originales.
- **Aleatoriedad en las Características:** En cada división de un nodo, el árbol busca en un subconjunto aleatorio de estas.

Beneficios del Modelo

- **Reducción del Sobreajuste:** Al promediar múltiples árboles, el error de generalización disminuye.
- **Estabilidad Mejorada:** Las variaciones en los datos tienen un impacto reducido en el modelo final.
- **Precisión Elevada:** El consenso de múltiples modelos suele capturar mejor el patrón general de los datos.

5. Hiperparámetros Críticos en Random Forest

El rendimiento de un Random Forest depende del ajuste de sus hiperparámetros, los cuales regulan la complejidad y el coste computacional:

Hiperparámetro	Función Impacto
`n_estimators`	Número de árboles en el bosque. Valores altos mejoran el rendimiento sin causar sobreajuste, pero aumentan el coste computacional.

`max_depth`	Profundidad máxima de los árboles. Limitarla ayuda a evitar el sobreajuste y favorece la generalización.
`max_features`	Número de características a considerar en cada nodo. Esencial para la aleatoriedad del modelo
`min_samples_split`	Mínimo de ejemplos para dividir un nodo; evita divisiones basadas en pocos datos.
`min_samples_leaf`	Mínimo de ejemplos en una hoja; ayuda a suavizar el modelo en presencia de ruido.
`bootstrap`	Define si se usa muestreo con reemplazo. Si es `True`, habilita el uso de métricas OOB.

Evaluación, optimización e implementación de modelos de aprendizaje supervisado.

1. Evaluación del modelo

Se utiliza para medir el rendimiento, fiabilidad y mejorar la precisión, lo que nos permite comprobar si el modelo aprende y predice correctamente.

Para evaluar los modelos se siguen una serie de pasos:

1. **División del conjunto de datos:** El modelo debe dividirse en 3 partes:
   a. **Conjunto de entrenamiento (Train Set):** Contiene un 70% - 80% de los datos y se utiliza para entrenar el modelo y ajustar parámetros internos.
   b. **Conjunto de validación (Validation Set):** Contiene un 10% - 15% de los datos y se utiliza para ajustar los hiperparámetros del modelo y detectar sobreajuste.
   c. **Conjunto de prueba (Test Set):** Contiene un 10% - 15% de los datos y se utiliza para medir el rendimiento real del modelo.

   Algunas veces se utiliza la **validación cruzada (Cross-Validation)** utilizando el método K-Fold que divide los datos en K partes y entrena el modelo varias veces permitiendo una evaluación más robusta y una reducción del sesgo.
2. **Selección de métricas de evaluación:** Según el tipo de problema se seleccionan:

a. Clasificación: Se utiliza la matriz de confusión, la exactitud, la precisión, el recall o el F1-Score.

b. Regresión: Se utiliza el Error Cuadrático Medio (MSE), error absoluto medio (MAE) o la raíz del error cuadrático medio (RMSE).

3. **Evaluación en el conjunto de validación:** En esta fase se realizan tareas como:

   a. Ajustar hiperparámetros mediante técnicas como Grid Search o Random Search.

   b. Aplicar técnicas de regulación como Early Stopping.

   c. Detectar problemas de sobreajuste o subajuste.

   Si el modelo no ofrece buenos resultados se aplican mejoras como la incorporación de más datos, la modificación de la arquitectura del modelo o la aplicación de técnicas de ingeniería de características.

4. **Evaluación en el conjunto de prueba:** El conjunto de prueba está formado por datos no vistos anteriormente, midiendo la capacidad real de generalización.

5. **Análisis de errores y comparación de modelos:** Si el modelo no tiene el rendimiento esperado se analizan los errores y se comparan diferentes modelos para identificar las causas y se selecciona la solución más adecuada.

6. **Monitoreo y mantenimiento en producción:** Después del despliegue se realiza un seguimiento del comportamiento del modelo. Las tareas más importantes se encuentran:

   a. Monitorizar el rendimiento del modelo con nuevos datos.

   b. Detectar fenómenos de concept drift (cambios en la distribución de los datos que puedan afectar a la precisión).

   c. Reentrenar el modelo cuando su rendimiento comience a degradarse.

2. Métricas

Evaluación de problemas de clasificación: Se centra en analizar hasta que punto un modelo es capaz de asignar correctamente una etiqueta. Los pasos que seguimos son los siguientes:

1. **Preparación de los datos de prueba:** Se evalúa el comportamiento del modelo con datos nuevos.
2. **Realización de predicciones:** El modelo se aplica sobre el conjunto de prueba para generar las etiquetas y posteriormente se comparan con los valores reales.
3. **Cálculo de métricas de evaluación:** Se comparan las etiquetas reales con las predicciones del modelo y se calculan las métricas clave que permiten analizar su rendimiento.

Matriz de Confusión: Es una tabla que muestra la relación entre las predicciones del modelo y las clases reales para identificar los aciertos y los fallos. Se utiliza en modelos de clasificación.

La matriz de confusión se organiza de la siguiente forma:

- **TP (True Positives):** Casos positivos correctamente clasificados como positivos.
- **TN (True Negatives):** Casos negativos correctamente clasificados como negativos.
- **FP (False Positives):** Casos negativos que el modelo ha clasificado incorrectamente como positivos (error de tipo I).
- **FN (False Negatives):** Casos positivos que el modelo ha clasificado incorrectamente como negativos.

En problemas de **clasificación multiclase** la matriz de confusión se amplía con filas y columnas adicionales, viendo el número de veces que una clase real ha sido predicha incorrectamente.

Métricas derivadas de Matriz de Confusión: Estas métricas proporcionan información sobre la calidad del modelo y ayudan a interpretar aciertos y errores.

- **Exactitud o accuaracy:** Mide la proporción de predicciones correctas comparado con el total de predicciones. Su valor es un porcentaje o un valor entre 0 y 1. Es efectiva cuando trabaja con conjuntos de datos balanceados.

$$Accuracy = \frac{Total\ verdaderos}{Total} = \frac{VP + VN}{VP + VN + FP + FN}$$

- **Precisión:** Mide la proporción de elementos correctamente clasificados como positivos entre todos los que el modelo ha clasificado como positivos. Es efectiva cuando se desea reducir los falsos positivos.

$$Precisión = \frac{Verdaderos\ positivos}{Total\ positivos\ predichos} = \frac{VP}{VP + FP}$$

- **Recall o sensibilidad:** Indica la proporción de ejemplos positivos identificados correctamente con respecto al total de ejemplos positivos reales. Es efectiva cuando interesa minimizar los falsos negativos.

$$Recall = \frac{Verdaderos\ positivos}{Total\ positivos\ reales} = \frac{VP}{VP + FN}$$

- **F1 score:** Combina las métricas de precisión y recall en un único valor, proporcionando una media equilibrada del rendimiento del modelo. Es efectiva cuando trabaja con datos no balanceados.

$$F1 = media_armónica_{(Precisión,Recall)} = \frac{2}{\frac{1}{Precisión} + \frac{1}{Recall}} = \frac{2 \cdot Precisión \cdot Recall}{Precisón + Recall}$$

Evaluación de problemas de regresión: El objetivo de estos modelos es aproximarse al valor real. La evaluación se centra en medir la distancia entre las predicciones del modelo y los valores reales. Para evaluar el rendimiento se utilizan métricas que comparan los valores predichos con valores reales. Estas métricas son:

- **Error Absoluto Medio (MAE - Mean Absolute Error):** Mide el promedio de los errores absolutos entre la predicción y el valor real. Características:
    - Fácil de entender porque mide el error en las mismas unidades que la variable de salida.
    - Cuanto menor sea el MAE, mejor será el modelo.
    - No penaliza errores grandes de manera significativa.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

- **Error Cuadrático Medio (MSE - Mean Squared Error):** Promedio de los errores al cuadrado, penalizando más los errores grandes. Características:
  - Penaliza más los errores grandes.
  - Cuanto menor sea el MSE, mejor será el modelo.
  - Un MSE bajo indica un buen ajuste, pero es más sensible a valores atípicos.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

- **Raíz del Error Cuadrático Medio (RMSE - Root Mean Squared Error):** Es la raíz cuadrada del MSE. Características:
  - Penaliza más los errores grandes.
  - Está en las mismas unidades que la variable objetivo.
  - Cuanto menor sea el RMSE, mejor será el modelo.

$$RMSE = \sqrt{MSE}$$

- **Coeficiente de Determinación (R^2 - R Squared):** Mide qué porcentaje de la variabilidad de la variable objetivo es explicada por el modelo.
  - Va de 0 a 1 (aunque en algunos casos puede ser negativo).
  - Si R2 = 1, el modelo explica la variabilidad de los datos.
  - Si R2 = 0, el modelo no explica nada mejor que el promedio de los datos.
  - Si R2 es negativo, significa que el modelo es peor que simplemente predecir el promedio de los valores reales.

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

(y_i— Valor real observado
$\hat{y}_i$— Valor predicho por el modelo
$\bar{y}$ es la media de todos los y_i)

3. Validación

Proceso mediante el cual evaluamos la capacidad de un modelo para generalizar a datos no vistos.

3.1 Validación cruzada

Permite comprobar si el modelo generaliza correctamente y no se ajusta a los datos de entrenamiento. Su objetivo es evitar el sobreajuste. Existen diferentes técnicas de validación cruzada:

- **Validación cruzada de K iteraciones (K-Fold Cross-Validation):**
  - El conjunto de datos se divide en K partes o folds de tamaño similar.
  - En cada iteración, se utilizan todos como conjunto de entrenamiento menos uno que se utiliza como prueba.
  - El proceso se repite K veces, utilizando un fold diferente en cada iteración.
  - Finalmente, se promedian los resultados obtenidos para calcular una métrica global de rendimiento.
  - Ventajas:
    - Cada dato se utiliza para entrenar y evaluar.
    - Reduce el error asociado a una única partición del conjunto de datos.
  - Desventaja:
    - Es computacionalmente costoso cuando se utilizan valores elevados de K.
  - Cuando se usa:

        - Cuando se dispone de un conjunto de datos de tamaño mediano/grande y se busca un equilibro entre precisión en la evaluación y coste computacional.
        - Quieres minimizar el sesgo.
        - Se necesita un método estructurado y consistente para comparar modelos.
    - Evitar su uso cuando:
        - El conjunto de datos es muy pequeño y cada fold contiene muy pocas muestras para entrenar.
        - Los recursos computacionales son muy limitados y se emplean valores altos de K.
    - Ejemplos de aplicación:
        - Problemas de clasificación o regresión.
        - Comparación de múltiples modelos utilizando un método de evaluación uniforme.
- **Validación cruzada aleatoria (Random Cross-Validation):**
    - Genera múltiples particiones aleatorias del conjunto de datos en conjuntos de entrenamiento y prueba.
    - En cada iteración, los datos se seleccionan de forma aleatoria para entrenamiento y prueba.
    - No existe una estructura fija de particiones, como ocurre en K-Fold.
    - Ventajas:
        - Es un método flexible y rápido.
        - Resulta útil cuando no es posible estructurar fácilmente el conjunto de datos.
    - Desventajas:
        - Es menos sistemático.
        - No garantiza que todos los datos se utilicen de forma uniforme en la evaluación.
    - Cuando se usa:

        - Con un conjunto de datos grande
        - Se busca una validación rápida y flexible
        - Se trabaja con datos que pueden cambiar en el tiempo
    - Evitar su uso cuando:
        - Se neceista una evaluación uniforme y estructurada
        - Cuando queremos que las muestras se utilicen tanto en entrenamiento como en prueba.
    - Ejemplos de aplicación:
        - Modelos en los que el conjunto de datos se actualiza o modifica de forma regular.
        - Experimentos rápidos con diferentes particiones de entrenamiento y prueba.
- **Validación cruzada dejando uno fuera (Leave-One-Out Cross-Validation, LOOCV):**
    - El número de folds es igual al número total de muestras del conjunto de datos.
    - En cada iteración, una única muestra se utiliza como conjunto de prueba.
    - Todas las muestras restantes se emplean para entrenar el modelo.
    - El proceso se repite tantas veces como muestras haya en el conjunto de datos.
    - Ventajas:
        - Aprovecha al máximo los datos disponibles.
    - Desventajas:
        - Presenta un coste computacional muy elevado.
        - No es recomendable para conjuntos de datos grandes.
    - Se recomienda su uso:
        - Conjunto de datos muy pequeños.
        - Se aprovecha al máximo el conjunto de entrenamiento en cada interacción.

        - Se busca obtener la estimación del error más precisa posible sin perder información.
    - Evitar su uso cuando:
        - El conjunto de datos es grande, ya que el coste computacional sería excesivo.
        - Se emplean modelos complejos que requieren un tiempo elevado de entrenamiento.
    - Ejemplos de aplicación:
        - Ámbitos como la medicina o la biología, donde los datos de pacientes suelen ser limitados.
        - Problemas en los que las muestras son costosas o difíciles de obtener.

4. Optimización de hiperparámetros

Consiste en encontrar la combinación de valores que permite maximizar el rendimiento del modelo mediante una métrica de evaluación.

Proceso de optimización de hiperparámetros: Se lleva a cabo habitualmente mediante **procesos de búsqueda** y el objetivo es encontrar la mejor selección de valores dentro de un conjunto de posibles combinaciones.

- **El espacio de estados** está formado por todas las posibles configuraciones de hiperparámetros.
- **Las acciones** corresponden a las operaciones que generan nuevas configuraciones dentro de ese espacio de búsqueda.
- **La función objetivo** guía el proceso de búsqueda, permitiendo evaluar cada configuración y decidir cuál ofrece mejores resultados.

Este proceso suele ser computacionalmente costoso puesto que entrenas el modelo múltiples veces modificando de forma conjunta los hiperparámetros.

Búsqueda aleatoria (Random Search): Explora el espacio de hiperparámetros de forma aleatoria dentro de un espacio de búsqueda finito. Los hiperparámetros se generan seleccionando valores al azar dentro de los rangos definidos. Este método permite explorar el espacio de búsqueda de forma eficiente.

Búsqueda en cuadrícula (Grid Search): Combina todos los valores posibles para generar una cuadrícula de configuraciones. El proceso de búsqueda recorre todas las combinaciones definidas en la cuadrícula, evaluando cada una de ellas mediante la **función objetivo.** Aunque este método ofrece resultados completos, su principal inconveniente es el alto coste computacional.

5. Datasets no balanceados

En los conjuntos de datos utilizados es frecuente que una de las clases esté representada por un número menor en comparación con el resto. Esta diferencia da lugar a lo que se conoce como un dataset no balanceado.

Impacto del desbalance de clases: Donde más se nota es en la capacidad de generalización de los algoritmos de aprendizaje automático.

Consecuencias en el rendimiento del modelo: Un bajo valor de recall en la clase minoritaria puede dar lugar a modelos aparentemente eficaces, pero poco fiables en la práctica.

5.1 Tratamiento de los datos en datasets desbalanceados

Hay técnicas para reducir el problema que consisten en modificar la distribución de las clases:

- **Submuestreo (Under-sampling):** Consiste en reducir el número de muestras de la clase mayoritaria. Para ello se eliminan instancias aleatoriamente o con métodos avanzados, siempre y cuando haya muchos ejemplos en la clase predominante.
    - Ventajas: Reducción del tiempo de entrenamiento y mejora del rendimiento en modelos simples.
    - Desventajas: Pérdida de información importante y riesgo de eliminar muestras representativas
- **Sobremuestreo (Over-sampling):** Consiste en aumentar el número de ejemplos de la clase minoritaria añadiendo nuevos ejemplos, para que así el modelo aprende mejor los patrones.
    - Métodos:
        - **Duplicación de muestras:** consiste en copiar datos hasta equilibrar las clases.

        - **Generación de datos sintéticos:** Se crean muestras artificiales mediante **SMOTE** (Synthetic Minority Over-sampling Technique) o **ADASYN** (Adaptive Synthetic Sampling).
    - Ventajas: Conservación de la información y mejora en la detección de la clase minoritaria.
    - Desventajas: Riesgo de sobreajuste y mayor coste computacional.

5.2 Detección de anomalías

Es una técnica de aprendizaje automático cuyo objetivo es identificar patrones inusuales dentro de un conjunto de datos. Se aplica en sectores como la industria, sanidad y en el sector financiero.

Un problema es la **alta dimensionalidad de los datos** (presencia de un gran número de variables) lo que dificulta la identificación de patrones anómalos y reduce el rendimiento de los modelos. Para ello se emplean técnicas como el PCA (Análisis de Componentes Principales), los Autoencoders y el Isolation Forest.

La reducción de dimensionalidad contribuye a:

- Eliminar redundancias en los datos.
- Reducir el ruido.
- Mejorar la capacidad del modelo para detectar comportamientos anómalos.

El PCA (Análisis de Componentes Principales): Transforma los datos originales en un nuevo conjunto de variables, denominadas componentes principales, que capturan la mayor parte de la varianza presente en los datos.

- Aplicación en detección de anomalías:
    - Los datos se proyectan en un espacio de menor dimensión y posteriormente se reconstruyen.
    - Las anomalías suelen presentar errores de reconstrucción elevados, ya que no siguen la estructura general de los datos normales.
    - Para identificar observaciones anómalas se pueden utilizar métricas como la distancia de **Mahalanobis** o el error de reconstrucción.
- Ventajas:
    - Reduce el ruido y la redundancia en los datos.

    - Facilita la visualización de los datos en espacios de menor dimensión.
    - Ayuda a identificar anomalías a partir del análisis de la reconstrucción.
- Desventajas.
    - Puede perder información relevante si la reducción de dimensionalidad es excesiva.
    - No resulta tan eficaz cuando las anomalías no se diferencian claramente en los componentes principales.
- Cuando utilizar esta técnica:
    - Se trabaja con datos de alta dimensionalidad

Los autoencoders (redes neuronales para reducción de dimensionalidad): Son redes neuronales diseñadas para aprender una representación comprimida de los datos y reconstruirlos posteriormente. Están formados por dos partes principales el **codificador** (reduce la dimensionalidad de los datos de entrada) y el **decodificador** (reconstruye los datos originales a partir de la representación comprimida).

- Aplicación en detección de anomalías:
    - Se entrenan utilizando datos normales.
    - Cuando se introduce una anomalía, el modelo presenta dificultades para reconstruirla, generando un error de reconstrucción elevado.
    - A partir de un umbral de error, es posible clasificar las observaciones como normales o anómalas.
- Ventajas:
    - Son más flexibles que PCA, ya que pueden aprender relaciones no lineales.
    - Permiten detectar anomalías más complejas.
    - Se adaptan mejor a conjuntos de datos de alta dimensión.
- Desventajas:
    - Presentan un mayor coste computacional que PCA.
    - Requieren una cantidad suficiente de datos normales para entrenarse correctamente.
- Cuando utilizar esta técnica:

    - Cuando los datos presentan estructuras complejas y no lineales.

Los Isolation Forest es un algoritmo basado en árboles diseñado para la detección de anomalías. Su funcionamiento se basa en la idea de que las anomalías son más fáciles de aislar

- Aplicación en detección de anomalías:
    - Se construyen múltiples árboles aleatorios, dividiendo los datos aleatoriamente.
    - Las observaciones que requieren menos divisiones para quedar aisladas se consideran anomalías.
    - El modelo asigna un puntaje de anomalía basado en la profundidad media de los árboles.
- Ventajas:
    - No requiere datos etiquetados.
    - Funciona de forma eficiente con grandes volúmenes de datos.
    - Es más rápido que muchos métodos basados en distancias.
- Desventajas:
    - Puede ser menos preciso cuando los datos presentan estructuras muy complejas.
    - Su rendimiento depende del número de árboles utilizados.
- Cuando utilizar esta técnica:
    - Cuando se trabaja con grandes volúmenes de datos.

6. Implementación del modelo para realizar predicciones sobre nuevos datos.

Es la etapa donde el modelo se utiliza para realizar predicciones sobre datos nuevos.

1. **Implementación del modelo:** Consiste en poner en funcionamiento un modelo previamente entrenado para que pueda generar predicciones útiles. Durante esta fase:
    - El modelo no aprende ni modifica sus parámetros internos.
    - Únicamente aplica el conocimiento adquirido durante el entrenamiento.

- Se utiliza como apoyo a la toma de decisiones o para la automatización de procesos.

La implementación se lleva acabo:

- Entornos de pruebas.
- Aplicaciones locales.
- Sistemas productivos o entornos reales.

2. **Uso del modelo entrenado:** Es el proceso mediante el cual el modelo recibe un conjunto de datos de entrada y genera una predicción como salida.
3. **Preparación de nuevos datos para la predicción:** Los nuevos datos deben cumplir las mismas condiciones que los datos utilizados durante el entrenamiento. Esto implica:
   - Mantener la misma estructura de variables.
   - Respetar el mismo orden de las características.
   - Aplicar los mismos procesos de preprocesado, tales como:
     - Normalización.
     - Codificación de variables categóricas.
     - Tratamiento de valores nulos.
4. **Realización de predicciones:** Una vez preparados los datos, el modelo puede generar predicciones sobre ellos.
5. **Interpretación de las predicciones:** Las predicciones generadas por el modelo deben analizarse teniendo en cuenta:
   - El contexto del problema.
   - Las métricas obtenidas durante la evaluación.
   - El nivel de confianza del modelo.

   En algunos modelos, además de la predicción final, se puede obtener información adicional como:

   - La probabilidad asociada a cada clase (en clasificación).
   - Intervalos de confianza (en regresión).
6. **Limitaciones en la predicción sobre nuevos datos:** Los modelos de aprendizaje supervisado presentan diversas limitaciones en la fase de

implementación:

- No garantizan aciertos en todos los casos.
- Pueden fallar si los nuevos datos difieren de los datos de entrenamiento.
- Son sensibles a cambios en la distribución de los datos, fenómeno conocido como concept drift.

Por este motivo, es fundamental:

- No confiar ciegamente en las predicciones.
- Mantener supervisión humana.
- Revisar y evaluar periódicamente el rendimiento del modelo.

7. **Uso responsable del modelo en producción:** Antes de utilizar un modelo en un entorno real, es necesario:
   - Definir claramente su propósito y ámbito de aplicación.
   - Establecer límites de uso.
   - Documentar su funcionamiento, supuestos y restricciones.
8. **Relación con el proceso completo de aprendizaje supervisado:** La implementación del modelo cierra el ciclo completo del aprendizaje supervisado, que incluye las siguientes fases:
   a. Preparación de los datos.
   b. Entrenamiento del modelo.
   c. Evaluación.
   d. Ajuste y optimización.
   e. Implementación y predicción.